UTN AVELLANEDA
Tecnicatura Universitaria en Programación

Materia:	Introducción al Análisis de Datos		
Nivel:	2º Cuatrimestre		
Tipo de Examen:	Segundo Parcial		
Apellido[1]:		Fecha:	octubre 2026
Nombre/s[1]:		Docente a cargo[2]:	Zotti, Enzo Martín
División[1]:	343	Nota[2]:	
DNI[1]:		Firma[2]:	

(1) Campos a completar solo por el estudiante en caso de imprimir este enunciado en papel.
(2) Campos a completar solo por el docente en caso de imprimir este enunciado en papel.

Consigna del Trabajo Práctico Integrador (TPI)

1. Objetivos Pedagógicos y Fundamentación

El Trabajo Práctico Integrador (TPI) constituye la instancia de evaluación sumativa de la materia. Este documento establece los requerimientos analíticos y técnicos que los estudiantes deberán desarrollar de manera autónoma a lo largo de la segunda mitad del cuatrimestre.

El propósito central de la actividad es aplicar de manera articulada las herramientas de manipulación de datos, análisis estadístico, preprocesamiento y modelado predictivo vistas en la materia, resolviendo un caso de estudio sobre un conjunto de datos real.

2. Formato de Entrega y Componentes Obligatorios

La entrega del proyecto se realizará mediante la publicación de un repositorio público en GitHub, el cual deberá estructurarse estrictamente según el estándar presentado a continuación:

```
tpi-analisis-de-datos/
├── data/
│   ├── raw/                # Archivos de datos originales (ej. WA_Fn-UseC_-Telco-Customer-Churn.csv)
│   └── processed/          # Datasets depurados, transformados e integrados
├── notebooks/
│   └── TPI_Analisis_de_Datos.ipynb  # Notebook oficial ejecutable en Google Colab
├── docs/
│   └── INFORME_EJECUTIVO.pdf # Informe técnico formal y de resultados
└── README.md               # Portada del proyecto, tecnologías, integrantes y enlace a Colab
```

Componentes Obligatorios

Jupyter Notebook (notebooks/TPI_Analisis_de_Datos.ipynb)

Desarrollado y optimizado para su ejecución directa en Google Colab (debe incluir el botón/badge interactivo "Open in Colab"). Debe ejecutarse en su totalidad de forma secuencial, limpia y sin errores de código.

Informe Técnico-Ejecutivo (docs/INFORME_EJECUTIVO.pdf):

Documento formal en PDF que debe contar obligatoriamente con una carátula inicial (nombre de la materia, título del proyecto, nómina de integrantes del grupo y fecha). En su cuerpo principal desarrollará con profundidad la metodología aplicada, el análisis exploratorio, la justificación de los modelos predictivos evaluados, las métricas obtenidas y las conclusiones estratégicas orientadas a la toma de decisiones de negocio.

Portada del Repositorio (README.md)

Documento de presentación principal en la raíz del repositorio. Debe incluir:

- Título del proyecto y descripción sintética del problema de negocio.
- Integrantes del grupo y división.
- Badge / Enlace directo para abrir el notebook en Google Colab.
- Stack tecnológico y librerías clave utilizadas (Python, Pandas, NumPy, Scikit-Learn, Seaborn, etc.).
- Guía rápida de la estructura del repositorio y cómo explorar el proyecto.

3. Origen de los Datos

Dataset Principal: Telco Customer Churn (Kaggle)

Descripción: Registro histórico de clientes de un servicio de telecomunicaciones que integra variables sociodemográficas, características de contratación, desglose de facturación y estado de cancelación de la suscripción (Churn).

4. Requerimientos Analíticos

Se espera que los estudiantes incorporen progresivamente en su trabajo los contenidos del programa a medida que avancen en el desarrollo autónomo del proyecto:

A. Fundamentos, Ingesta y Limpieza de Datos

Fundamentos

- Definición clara del problema de negocio a abordar, planteo de hipótesis analíticas e identificación de la variable objetivo.
- Clasificación del Dataset y Variables: Identificación y justificación del tipo de datos según su estructura (estructurado, semi-estructurado o no estructurado) para el dataset Telco Customer Churn. Asimismo, se deberá incluir un relevamiento formal del tipo de variables presentes en el dataset (distinguiendo entre cualitativas/categóricas —nominales, ordinales— y cuantitativas —discretas, continuas—), contrastando esta clasificación teórica con los tipos de datos asignados por defecto en la librería Pandas (`dtypes`).

Manipulación de Datos

Manipulación de conjuntos de datos estructurados utilizando Pandas mediante:

- Carga y Selección: Ingesta de datos y filtrado avanzado con múltiples condiciones lógicas (operadores `&`, `|`).
- Agregación: Resumen estadístico y segmentación del negocio mediante `groupby` combinando múltiples agregaciones (promedios, conteos, sumas).
- Transformación Básica: Renombrado de columnas, eliminación de atributos irrelevantes y creación de columnas calculadas mediante operaciones aritméticas directas entre variables.

Limpieza de Datos y Calidad de Datos

- Tratamiento de Valores Faltantes y Cadenas Anómalas: Detección, imputación o eliminación fundamentada de valores nulos y cadenas de texto anómalas (por ejemplo, espacios vacíos `""` en la variable `TotalCharges`).
- Adecuación de Tipos de Datos: Corrección y conversión formal de tipos de datos en Pandas (`dtypes`).
- Gestión de Valores Atípicos (Outliers): Identificación analítica de valores atípicos (mediante diagrama de caja / método del rango intercuartílico IQR) y justificación de su tratamiento o conservación.

B. Análisis Exploratorio, Visualización e Integración

Análisis Exploratorio de Datos y Estadística Aplicada

- Análisis Cuantitativo: Determinación e interpretación de medidas de tendencia central, dispersión y análisis de correlación lineal (Pearson/Spearman) para comprender la relación entre variables numéricas (`tenure`, `MonthlyCharges`, `TotalCharges`).
- Análisis Categórico: Cálculo de frecuencias absolutas, relativas y tablas de contingencia para evaluar la distribución de las características sociodemográficas y de contratación respecto al Churn.

Visualización de Datos

Construcción de un reporte gráfico utilizando Matplotlib y Seaborn que incluya:

- Histogramas/KDE de la antigüedad (`tenure`) y cargos mensuales (`MonthlyCharges`).
- Representación gráfica de la matriz de correlación (Heatmap).
- Diagramas de barras comparativos para evaluar la tasa de cancelación (`Churn`) según variables categóricas (tipo de contrato y modalidad de pago).

Cada gráfico debe estar acompañado por una breve interpretación analítica orientada al impacto en el negocio.

C. Preprocesamiento y Modelado Predictivo (Temas 9, 10, 11)

Preprocesamiento de Datos para Modelado (Tema 9)

- Transformación de variables categóricas mediante codificación nominal (One-Hot Encoding) u ordinal (*Label / Ordinal Encoding*).
- Normalización o estandarización de atributos cuantitativos (`StandardScaler`/`MinMaxScaler`).
- Partición estratificada en conjuntos de entrenamiento y evaluación (`train_test_split`, proporción 80/20).

Predicción Numérica: Modelos de Regresión

Entrenamiento de un modelo básico de Regresión Lineal Simple para estimar una variable continua (por ejemplo, `TotalCharges`). Evaluación simple mediante el coeficiente de determinación R^2 y el Error Medio Absoluto (MAE).

Predicción Categórica: Modelos de Clasificación

Entrenamiento de un único modelo de clasificación elemental (por ejemplo, Regresión Logística o Árbol de Decisión) para predecir la variable binaria `Churn`. Evaluación básica mediante la Matriz de Confusión y la métrica de Exactitud (Accuracy).

D. Reproducibilidad y Buenas Prácticas

Reproducibilidad, Versionado y Buenas Prácticas

Uso riguroso de control de versiones Git con mensajes de confirmación (commits) descriptivos, estructuración limpia del repositorio, archivo `README.md` explicativo y entorno reproducible en Google Colab.

5. Evaluación Integral — Exposición y Defensa del TPI

La evaluación final del TPI se desarrollará durante la Clase 15 y contemplará tres instancias complementarias:

- Auditoría de Código e Informe: Corrección del repositorio publicado en GitHub, verificando la validez técnica del notebook en Google Colab y la profundidad del informe escrito.
- Exposición Oral del Grupo: Disertación académica y técnica con apoyo visual de 12 a 15 minutos de duración.
- Defensa e Interrogatorio Individual: Instancia de preguntas de validación donde cada alumno deberá justificar las decisiones metodológicas y la implementación del código desarrollado.

6. Rúbrica de Ponderación Académica

Dimensión de Evaluación	Ponderación	Criterios Específicos
Limpieza y Preparación de Datos	**20%**	Correcta depuración de nulos, outliers, adecuación de dtypes, integración de datos e ingeniería de atributos.
Análisis Exploratorio y Visualización	**25%**	Rigor en la interpretación estadística y calidad en el diseño comunicacional de los gráficos
Modelado y Evaluación (ML)	**20%**	Rigor metodológico (prevención de data leakage), justificación de algoritmos y solidez en la interpretación y evaluación de modelos de Regresión y Clasificación.
Colab, Repositorio Git e Informe	**20%**	Funcionamiento del notebook en Google Colab, organización formal en GitHub e informe técnico escrito en PDF (con carátula).
Defensa Oral y Argumentación	**15%**	Capacidad de síntesis, dominio conceptual individual y precisión en las respuestas teóricas.

7. Disposiciones Generales

Entrega: El enlace al repositorio de GitHub deberá ser entregado mediante el campus institucional antes del inicio de la Clase 15.
Modalidad de Trabajo: El Trabajo Práctico Integrador se realizará en grupos de 4 integrantes.